

Постановка задачи и требования

Интеллектуальный подбор стикеров и открыток

Промежуточный отчёт по проекту курса компьютерного зрения. Обновление: 27 сентября 2026 года.

Система получает свободный русскоязычный запрос и возвращает изображения, подходящие для отправки в заданной ситуации. Например, «поддержать друга перед экзаменом» задаёт намерение и тон; «кот с кофе» - визуальный объект; «с днём рождения без надписи» - повод и явное ограничение.

Требование	Критерий проверки
Поиск стикеров и открыток	Топ-5; фильтр типа изображения; несколько допустимых ответов
Учёт визуального смысла и надписи	Сравнение image-only, OCR и гибрида; разбор ошибок текста
Русские запросы	Мультиязычный текстовый энкодер; отдельная RU-оценка на этапе 2
Воспроизводимость	Фиксированные ревизии, seed=42, manifest и SHA-256
Скорость	Проектная цель р95 полного поиска <1 с; измерить на целевой машине
Генерация при неудовлетворительном поиске	Готовая генеративная модель, автоматическое удаление фона и RGBA PNG на этапе 2

Фактически выполнено: собран каталог из 30,914 изображений, проведены проверка файлов, дедупликация, предварительный групповой split и EDA. На отдельном пилоте из 472 изображений рассчитаны нейросетевые признаки, проведены 5 эпох обучения и оценка. Полная GPU-разметка и независимая русская оценка ещё не выполнены.

Границы текущего решения: статические изображения; нет контекста переписки и персонализации. В каталоге есть сторонние персонажи и синтетические открытки. Успешное онлайн-демо остаётся обязательным условием итоговой оценки.

Источники и структура датасета

Часть	Получено после очистки	Разметка / источник
Telegram stickers	30 000	nyuuzyou/stickers [1]; исходная метка - emoji, описаний предложениями нет
StickerQueries	574	Английские поисковые запросы, проверенные авторами набора [2]
Synth-GCD	100	Синтетические открытки с английскими надписями внутри изображения [3]
OpenMoji-карточки	240	12 поводов × 2 рисунка × 5 шаблонов × с текстом/без текста [4]

Для большого каталога загружен valid.zip объёмом 6 598 157 862 байта; проверен опубликованный SHA-256. Среди кандидатов обеспечено начальное покрытие доступных emoji-категорий, затем выбран перемешанный остаток, seed=42. Этот архив используется как сырьё для собственного корпуса: официальное validation-разбиение источника не является нашим benchmark.

Английский CSV StickerQueries содержит 1 115 строк: 578 PNG и 537 GIF/WEBM. Все 578 PNG загружены; 4 повторяющихся изображений объединены. После очистки сохранено 4,171 пар «поисковая фраза - изображение». Запятые трактуются как разделители списка по схеме источника. Фразы не равнозначны независимым пользовательским сессиям.

Лицензии и происхождение

Авторы карточек датасетов заявляют WTFPL для [1], MIT для [2], Apache-2.0 для [3]. Графика OpenMoji [4] - CC BY-SA 4.0; производные композиции сохраняют атрибуцию и лицензию. Декларация набора не является независимой проверкой прав на каждый исходный рисунок. Корпус автоматически публично не публикуется.

Файл / поля	Назначение
manifest.jsonl	item_id, путь, источник, ревизия, контрольные суммы, размеры, прозрачность, группа и split
labels/queries_en.jsonl	query_id, текст, язык, известные позитивы, split; не входит в признаки поиска
annotations.jsonl (план)	VLM-caption, эмоция, стиль, OCR, синтетические train-запросы; происхождение разметки
audit/	Ошибки загрузки, точные дубликаты, кандидаты на близость и статистики

EDA: измеренные свойства и баланс




Рис. 1. Фактический состав каталога, split, доля непрозрачности и размеры групп после исправления правила группировки. Логарифмическая ось используется только для числа групп.

Проверка	Результат	Следствие
Состав	30,574 стикера; 340 открыток	Открытки составляют около 1,1%; общая метрика может скрыть их качество
Прозрачность	23,905 изображений с $\alpha < 255$	Для энкодера - композиция на белом фоне, без потери оригинального α
Точные дубликаты	4 объединены; 30,914 уникальных хешей	Одинаковые пиксели не попадают в разные группы
Декодирование и загрузка	Включённые файлы проверены; ошибок загрузки 0	Числа относятся к текущему snapshot, а не ко всему исходному набору

Неизвестные сейчас свойства: доля корректных будущих caption/OCR, качество русского перевода, частоты настоящих пользовательских сценариев. Их нельзя вывести из размеров картинок или наличия α .

EDA: примеры и пробелы покрытия




Рис. 2. По четыре примера каждого источника; первые ID в сохранённом manifest. Прозрачность показана на белом фоне. Изображения не выбирались по успешности поиска.

Корпус стикеров существенно больше корпуса открыток. Открытки полностью синтетические: 100 сгенерированных изображений и 24 шаблонных композиций. Для последних имеется лишь 24 независимых мотива. Повторение рамок и цветов не заменяет разнообразие сюжетов и реальных поздравительных формулировок.

GIF/WEBM исключены: смысл движения может потеряться при выборе одного кадра. У большого Telegram-корпуса вместо описания только emoji; одинаковая метка может объединять очень разные эмоции и сцены. Поэтому перенос метки emoji в длинное описание не считается качественной разметкой.

Представления и архитектура

Компонент	Представление	Обоснование / ограничение
Изображение	CLIP ViT-B/32, 512D, L2	Готовая связь изображения с текстом; ограничен на эмоциях и тонком смысле мемов
Запрос RU/EN	Согласованный multilingual CLIP text encoder [5], 512D	Русский и английский находятся в пространстве выбранного image encoder
Визуальное описание	Qwen2.5-VL-7B [6] → русский caption → text encoder	Добавляет явно выраженные предметы, стиль и эмоции; возможны галлюцинации
Надпись	Отдельное поле OCR → text encoder; char TF-IDF baseline	Точная надпись может менять смысл; OCR необходимо проверять отдельно
Метаданные	Тип и источник; группа для split	Фильтр стикеров/открыток. Оценочные запросы и эталонные сценарии не индексируются

Визуальные и текстовые векторы согласованы: используются image encoder исходного CLIP и специально дистиллированный в его пространство текстовый encoder. Произвольный BERT нельзя подставить в тот же скалярный продукт без выравнивания. Для прозрачных файлов фон явно приводится к белому; оригинал сохраняется.

Поиск и обучение

Baseline вычисляет $\cos(q, image)$. Гибрид смешивает image, caption и OCR с начальными весами 0,65 / 0,25 / 0,10, перенормированными по доступным ветвям. При пустом тексте работает визуальная ветвь. Обучаемые части: две residual-проекции rank=64 для query/image и три веса смешивания; основные энкодеры заморожены.

Целевая функция - multi-positive InfoNCE, temperature=0,07. Известные позитивы одинакового запроса не становятся отрицательными друг для друга; близкие изображения одной группы маскируются среди негативов. Неразмеченные семантические аналоги всё же могут остаться ложными отрицательными: это ограничение исходных меток.

Для 30 тыс. векторов 512D один FP32-массив занимает примерно 61 MB. Используется точное матричное произведение; сложный ANN-индекс пока не обоснован измерениями. DINO требует дополнительного выравнивания с текстом. SigLIP2 - кандидат следующего сравнения, но ещё не измеренная альтернатива.

Разбиение, перевод и протокол оценки

Полный каталог разделён на 21,805 train, 4,469 dev и 4,640 test изображений. Сначала объединяются точные дубликаты и известные семьи рисунков, затем применяется эвристика $dHash \leq 3$ с близкими пропорциями и средним цветом. Хеш группы с $seed=42$ задаёт split. Всего 30,508 групп.

При аудите обнаружены ложные объединения: одинаковые рамки открыток и большие пустые поля стикеров. Исправления: разные известные семейства рисунков не сливаются только по $dHash$; остальные кандидаты проверяются на обрезанных по содержимому миниатюрах 64×64 (IoU масок $\geq 0,85$; средняя RGB-ошибка $\leq 0,03$). Самая большая группа теперь содержит 10 изображений. Pack ID исходного Telegram-корпуса отсутствуют; независимость настоящих паков не гарантирована.

Защита от утечки

Английская фраза и русский перевод остаются в split исходного изображения. VLM-caption строится только по пикселям и не получает человеческих поисковых запросов. Синтетические ситуации использования применяются только как train-метки; не включаются напрямую в поисковый индекс. Изображения теста присутствуют среди кандидатов, но их пары с запросами не обучают модель.

Метрика	Смысл
Hit@5	Есть ли известный релевантный объект в первых пяти позициях
Recall@k по известным позитивам	Доля найденных известных позитивов; не полный recall при неполной разметке
NDCG@5	Дисконтирование низких позиций; для будущих оценок 0/1/2 учитывает степень релевантности
MRR@10	Обратная позиция первого известного позитива в top-10
p50/p95 и память	Раздельно online-поиск, кодирование запроса и offline-индексация

В исходных query-image парах не перечислены все подходящие картинки. В вычисленной проху-оценке неразмеченные кандидаты трактуются как 0; это позволяет проверить нахождение известного позитива, но не доказывает общую семантическую релевантность. Для итогового отчёта нужны независимые русские запросы и слепая оценка общего пула выдачи нескольких методов.

План: 100–200 русских запросов, стикеры и открытки, визуальные и текстовые ограничения, no-match случаи; оценки 0/1/2. На части данных - второй оценщик. Машинный перевод и синтетические запросы отдельно маркируются. Интервалы неопределённости считаются по группам изображений, а не по коррелированным перефразировкам.

Проверка подхода на отдельном CPU-пилоте

Пилот содержит 232 стикера StickerQueries и 240 OpenMoji-карточек. Это отдельный ранний snapshot с собственным split: 1176 обучающих, 250 validation и 224 тестовых английских запросов. Тест относится к 29 группам стикеров; качество открыток и русских запросов этими числами не измеряется.

Метод	Hit@5	NDCG@5	MRR@10
Замороженный multilingual CLIP	0.2054	0.1540	0.1448
Выбранный по dev checkpoint	То же	То же	То же




Рис. 3. Пять эпох обучения на замороженных признаках. Train-loss уменьшается, validation остаётся ниже исходного baseline. Выбор checkpoint включает эпоху 0.

Исходный dev NDCG@5 = 0.1147; лучший checkpoint - эпоха 0. Поэтому совпадение test-метрик двух строк объясняется возвратом исходной модели, а не улучшением от обучения. Пять эпох: AdamW, lr=0,001, batch=64, rank=64. Повторный CPU-запуск с seed=42 дал идентичный журнал потерь и dev-метрик.

Полученный результат не опровергает дообучение на полном корпусе: здесь мало размеченных изображений, отсутствуют новые caption/OCR-признаки и русская supervision. Одновременно он не даёт оснований обещать улучшение. На этапе 2 сравнение проводится на одном полном каталоге с заранее выбранным dev-протоколом.

Проверены 9 автоматических тестов: метрики, градиенты multi-positive loss, прозрачность, группировка и перенос архивов. Streamlit-интерфейс принимает русский запрос и возвращает выдачу без исключений. GPU-аннотация, генерация и реальное подключение YT пока не проверены.

Гипотезы и дальнейшая работа

Шаг	Эксперимент / действие	Критерий завершения
1. Разметка	Qwen2.5-VL на 500 примерах; проверить 50–100 вручную	Ошибки OCR, caption и эмоций посчитаны; измерена скорость
2. Масштабирование	Полная разметка; EN→RU перевод исходных запросов	Прошли schema-checks; сохранены модель, ревизия, prompt и источники меток
3. Сравнение	OCR TF-IDF; image-only; гибриды; обученные adapters	Один каталог, один test; выбор модели только по dev
4. Русская оценка	Независимые RU-запросы, pooled-оценки 0/1/2	Метрики по стикерам/открыткам, надписям и no-match; разбор ошибок
5. Генерация	FLUX.1-schnell + U2Net/rembg	Минимум пять реальных запусков, исходники/маски/PNG и время
6. Сдача	README, репозиторий, PDF 10–15 страниц, онлайн-демо	Работающее решение и объяснение ограничений; демо до 15 минут

Проверяемые гипотезы

H1: OCR улучшает запросы по надписи, но мало помогает на стикерах без текста. H2: визуальные caption и эмоции помогают запросам о намерении по сравнению с image-only. H3: обучение проекций на human-source и слабой разметке улучшает held-out retrieval. H4: перевод supervision помогает русским запросам; проверка требует отдельных русских меток.

Для генерации используется готовая FLUX.1-schnell [7], затем U2Net через rembg [8]. Исходник и RGBA сохраняются отдельно. Это реализация обязательного функционала этапа 2; код подготовлен, но результат генерации в текущем отчёте не предъявляется как выполненный. Точная кириллица не обещается: первая версия генерирует без надписей.

Рабочая среда пользователя: 4 × A100 80 GB. Предполагается предварительная загрузка данных и моделей, размещение архивов в YT и скачивание на локальный диск GPU-узла перед работой. Подготовлены checksum-архивы по 500 картинок и скрипты переноса. Конкретный кластер, каталог и рецепт запуска ещё не заданы.

Категории будущих ошибок: неверная эмоция при верном объекте; OCR и отрицание; ирония; культурная отсылка; потеря движения; открытка другого повода; отсутствие нужного сюжета; релевантный, но неразмеченный альтернативный ответ. Отдельно анализируется качество маски при удалении фона.

Воспроизводимость и источники

Комплект sticker_search_project.zip содержит код, manifest полного каталога, README, готовый CPU-пилот, его эмбединги, журналы экспериментов и checkpoint. Полные 30 тысяч исходных PNG восстанавливаются из закреплённого архива с проверкой каждого файла. Внешний GitHub/GitLab-репозиторий ещё не опубликован; его ссылку нужно добавить при сдаче.

Основные команды

```
python -m sticker_search.restore_catalog --output data/catalog
```

```
python -m sticker_search.audit --catalog data/catalog
```

```
bash scripts/run_gpu.sh
```

```
python -m streamlit run app.py
```

Прямые зависимости и модели закреплены в pyproject.toml и configs/model_revisions.json. Фактическая CPU-среда записана отдельно. Полный lock GPU-среды, версия CUDA и измерения A100 будут добавлены после запуска. Код и текст подготовлены с помощью AI; численные результаты получены выполнением скриптов. Ручная независимая оценка не заявляется.

[1] Telegram stickers, источник PNG

<https://huggingface.co/datasets/nyuuzyou/stickers>

[2] StickerQueries, человеческие query-image пары

<https://huggingface.co/datasets/metchee/sticker-queries>

[3] Synthetic Greeting Cards

<https://huggingface.co/datasets/gauravs101/synthetic-greeting-cards>

[4] OpenMoji: графика и лицензия

<https://github.com/hfg-gmuend/openmoji>

[5] Согласованный мультиязычный CLIP

<https://huggingface.co/sentence-transformers/clip-ViT-B-32-multilingual-v1>

[6] Qwen2.5-VL-7B-Instruct

<https://huggingface.co/Qwen/Qwen2.5-VL-7B-Instruct>

[7] FLUX.1-schnell

<https://huggingface.co/black-forest-labs/FLUX.1-schnell>

[8] rembg, удаление фона

<https://github.com/danielgatis/rembg>

[9] YTsaurus Python API

<https://ytsaurus.tech/docs/en/api/python/userdoc>

Материалы курса: лекции 5 «Metric learning», 6 «CLIP, DINO», 9 «Распознавание текста», 12 «Мультимодальные модели». Дата проверки внешних источников: 27.09.2026.